

INTELIGENCIA DE NEGOCIOS • [CURSO / UNIVERSIDAD]

Puntualidad aérea en EE. UU.

Un datamart dimensional con los microdatos del Bureau of Transportation Statistics



AGENDA

01 Marco teórico

02 Empresa y problemática de negocio

03 Diccionario de datos

04 Modelamiento de data dimensional

Modelamiento dimensional: los cuatro pasos de Kimball

01

Proceso de negocio

La ejecución de un segmento de vuelo, desde el bloqueo en puerta hasta el arribo.

02

Grano

Un segmento de vuelo programado, incluidos los cancelados y desviados.

03

Dimensiones

11 dimensiones:
10 conformadas y 1 degenerada (el número de vuelo).

04

Hechos

26 métricas base, clasificadas según su aditividad.

El grano se declara primero: define qué representa una fila de la tabla de hechos y condiciona todas las decisiones siguientes.

Aditividad: qué se puede sumar y qué no

Aditivas

Se suman en todas las dimensiones.

Flights
DepDelayMinutes
Distance

Semiaditivas

Instantáneas en el tiempo: se suman en algunas dimensiones, pero no a lo largo de la fecha.

No aditivas

Porcentajes y promedios. Sumarlos da un resultado sin sentido.

OTP %
Demora promedio

REGLA DEL PROYECTO

Se guardan el numerador y el denominador; la razón se calcula en la capa semántica.

$$\text{OTP} = 1 - \text{SUM}(\text{ArrDe15}) / \text{SUM}(\text{VuelosOperados})$$

El BTS y el reporte de puntualidad

Bureau of Transportation Statistics: Office of Airline Information del U.S. Department of Transportation.

MARCO REGULATORIO

14 CFR Part 234: reporte obligatorio de la calidad de servicio de las aerolíneas.

QUIÉN REPORTA

Las aerolíneas que superan un umbral de participación en el mercado doméstico.

USO PÚBLICO

El DOT publica rankings mensuales en el Air Travel Consumer Report.



Seis problemas que el data mart resuelve

P1

Atribución causal

No se atribuye cada demora a su origen de forma sistemática.

P2

Congestión

Se desconoce dónde y a qué hora se concentra la congestión.

P3

Benchmarking

No hay una comparación homogénea entre aerolínea, ruta y aeropuerto.

P4

Sesgo de itinerario

No se mide la brecha entre el tiempo programado (CRS) y el real.

P5

Propagación

No se traza cómo una demora pasa al siguiente vuelo de la misma aeronave.

P6

Análisis fragmentado

Cancelaciones, desvíos y demoras se analizan por separado.

La fuente: Reporting Carrier On-Time Performance

1

fila por segmento de vuelo
programado

10^5-10^6

registros por mes

$\sim 10^8$

filas en la serie histórica,
desde 1987

45-75

días de rezago en cada
publicación mensual

FORMATO

CSV comprimido en ZIP, más tablas
lookup independientes.

NATURALEZA

Dato primario, real y de reporte
obligatorio; no es sintético.

DESCARGA

transtats.bts.gov, por año y mes.

Campos clave del archivo de origen

Campo BTS	Qué representa	Uso en el modelo
FlightDate	Fecha del vuelo (salida)	DIM_FECHA
Reporting_Airline	Aerolínea que reporta	DIM_AEROLINEA
Tail_Number	Matrícula de la aeronave	DIM_AERONAVE
OriginAirportID · DestAirportID	Aeropuertos de origen y destino	DIM_AEROPUERTO, DIM_RUTA
DepTimeBlk · ArrTimeBlk	Bloque horario programado	DIM_BLOQUE_HORARIO
ArrDelayMinutes · ArrDel15	Demora de llegada y bandera ≥ 15 min	Métrica raíz y OTP
Cancelled · Diverted	Vuelo cancelado o desviado	DIM_ESTADO_VUELO
CarrierDelay ... LateAircraftDelay	Minutos de las cinco causas	Descomposición causal

Reglas para interpretar bien los datos

Nulos semánticos

ArrDelay vacío en un vuelo cancelado significa “no llegó”. No se imputa.

Horas locales

Todas las horas están en hora local del aeropuerto. La zona horaria permite llevarlas a UTC.

Cruce de medianoche

ArrTime menor que DepTime no es un error: FlightDate es la fecha de salida.

Causas condicionadas

Las cinco causas solo se llenan si ArrDel15 = 1. El denominador es su suma.

Cobertura desigual

Causas desde 06/2003 y desvíos desde 10/2008. Ventana recomendada: 2015 en adelante.

Validación en Silver

Consistencia aritmética, coherencia lógica, integridad referencial y rangos válidos.

Esquema en estrella con FACT_VUELO al centro



Las dimensiones en detalle

Dimensión	Tipo	Filas aprox.	Atributos destacados
DIM_FECHA	Conformada (ETL)	~4 000	Año, mes, feriado US, temporada
DIM_AEROLINEA	SCD2	Decenas	IATA, grupo corporativo, regional
DIM_AEROPUERTO	SCD2 · role-playing	~400 activos	Ciudad, estado, zona horaria, hub
DIM_AERONAVE	SCD2	7 000–10 000	Fabricante, modelo, asientos, edad
DIM_RUTA	SCD1 · derivada	6 000–8 000	Distancia, etapa, transcontinental
DIM_BLOQUE_HORARIO	Estática · role-playing	19	Franja operativa, banco pico
DIM_ESTADO_VUELO	Junk	~24	Cancelado, desviado, estado final
DIM_CAUSA_DEMORA	Estática	8	Controlabilidad, palanca de mitigación
DIM_CAUSA_CANCELACION	Estática	6	Controlabilidad, compensación DOT
DIM_RANGO_DEMORA	Banda · role-playing	~15	Etiqueta, severidad, umbrales

Métricas de FACT_VUELO y tablas complementarias

CONTEOS	Vuelos, operados, cancelados, desviados y puntuales (M01–M05)
DEMORA	Minutos de demora de llegada, la métrica raíz (M09), y bandera $\geq$ 15 min (M11)
TIEMPOS	Taxi-out, tiempo en aire y distancia (M12–M14)
CAUSAS	Aerolínea, clima, NAS, seguridad y aeronave tardía (M18–M22)
DERIVADAS	Minutos recuperados en ruta, varianza de tiempo de bloque, holgura de itinerario

FACT_DESVIO_ESCALA

Una fila por aterrizaje en un aeropuerto de desvío.

FACTLESS_VUELO_PROGRAMADO

Lo que se programó y no se operó.

FACT_VUELO_AGG_DIARIO

Día × aerolínea × origen × bloque: de $\sim 10^8$ a $\sim 10^6$ filas.

Los KPIs que habilita el modelo

OTP (A14)

% de vuelos que llegan con menos de 15 min de demora

$$1 - \frac{\text{SUM(ArrDel15)}}{\text{SUM(VuelosOperados)}}$$

D0

% de vuelos que salen a la hora o antes

$$\frac{\text{SUM(DepDelay} \leq 0)}{\text{SUM(Flights)}}$$

Completion Factor

% de vuelos programados que se operan

$$\frac{1 - \text{SUM(Cancelled)}}{\text{SUM(Programados)}}$$

Severidad de demora

Minutos promedio por vuelo demorado

$$\frac{\text{SUM(ArrDelayMinutes)}}{\text{SUM(ArrDel15)}}$$

Taxi-out

Rodaje en origen, un indicador de congestión

$$\frac{\text{SUM(TaxiOut)}}{\text{SUM(VuelosOperados)}}$$

Participación causal

Peso de cada causa en la demora total

$$\frac{\text{SUM(CausaX)}}{\text{SUM(cinco causas)}}$$



Gracias

Del dato crudo del BTS a un modelo que explica dónde, cuándo y por qué se demoran los vuelos.